



순위표용 Hugging Face URL 제출 규정: 글쓰기 채점 능력 평가

이 문서는 Hugging Face 모델 URL 또는 repo id 를 제출하는 참가자를 위한 지침입니다. Hugging Face URL 제출은 제출한 모델이 표준 vLLM 기반 평가 환경에서 바로 로드되고 평가까지 진행될 수 있어야 합니다.

1. 전체 동작 흐름

Hugging Face URL 제출이 들어오면 시스템은 아래 순서로 동작한다.

- 리더보드에서 다음 평가 대기 모델을 조회한다.
- 제출 정보의 **modelUrl** 을 Hugging Face repo id로 해석한다.
- 제출한 모델을 표준 vLLM 기반 평가 환경에서 로드한다.
- 이때 모델은 Hugging Face에서 직접 받아 로드한다.
- 모델 로드가 끝나면 벤치마크 평가를 진행한다.
- 평가가 끝나면 결과가 집계된다.

즉, Hugging Face URL 제출은 "표준 vLLM 기반 평가 환경에서 그대로 로드 가능한 모델"이어야 한다.

2. 이 제출 방식의 의미

Hugging Face URL 제출에서는 제출자가 직접 서빙 이미지를 제공하지 않는다. 주요 내용은 아래와 같다.

- 공개 Hugging Face repo 여야 한다.
- 별도 커스텀 환경 없이 바로 로드 가능한 모델일수록 적합하다.
- 모델 구조나 로드 방식이 특수할수록 Hugging Face URL 제출보다 Docker 이미지 제출이 더 적합할 수 있다.
- 평가 환경에서 바로 로드되지 않으면 평가는 시작되지 않고 실패 처리된다.

즉, 호환성이 애매한 모델이면 Hugging Face URL 제출보다 Docker 이미지 제출이 더 안전하다.

3. 어떤 modelURI를 넣어야 하는가

Hugging Face 전체 URL 예시는 아래와 같다.

- <https://huggingface.co/Qwen/Qwen3-4B-Instruct-2507>
- <http://huggingface.co/Qwen/Qwen3-4B-Instruct-2507>
- [Qwen/Qwen3-4B-Instruct-2507](#)

주의할 점은 다음과 같다.

- 브랜치, 특정 revision, 별도 파일 경로를 제출 인자로 함께 제어하는 기능은 없다.
- 기본적으로 공개적으로 접근 가능한 repo라고 가정한다.
- 인증 토큰이 필요한 private 또는 gated 모델은 이 경로에서 안정적으로 지원되지 않는다.

4. 긴 입력 처리와 설정 파일

Hugging Face URL 제출에서는 모델의 설정 파일을 바탕으로 입력 길이와 로드 설정이 해석된다. 즉, 긴 입력을 제대로 처리하려면 Hugging Face repo 의 설정 파일이 실제 모델과 일관되어 있어야 한다. 특히 다음을 주의해야 한다.

- **config.json** 이 없거나 주요 길이 정보가 빠져 있으면 긴 입력 처리 설정이 기대와 다르게 잡힐 수 있다.



- 모델은 장문을 처리할 수 있는데 설정이 짧게 적혀 있으면 평가 중 긴 입력에서 길이 제한 오류가 날 수 있다.
- 반대로 설정이 잘못되어 있으면 로드 단계에서 바로 실패할 수도 있다.

5. 평가 시 기대되는 동작

평가는 OpenAI 호환 Chat Completions 방식으로 진행된다. 즉, Hugging Face repo 자체가 장문 입력을 감당할 수 있도록 올바른 설정을 갖고 있어야 하고, 짧은 프롬프트만 통과하는 모델이 아니어야 한다.

6. Hugging Face URL 제출이 적합한 경우

아래 조건을 만족하면 Hugging Face URL 제출이 비교적 잘 맞는다.

- 공개 Hugging Face repo 로 누구나 다운로드 가능
 - 표준 vLLM 기반 평가 환경에서 별도 조치 없이 로드 가능
 - `config.json` , tokenizer 관련 파일이 완비되어 있음
 - 추가 커스텀 코드 의존성이 크지 않음
 - 긴 입력 길이 설정이 메타데이터에 올바르게 반영되어 있음
- 대부분의 일반적인 Transformers 호환 causal LM 은 이 경로로 충분할 수 있다.

7. Hugging Face URL 제출이 적합하지 않은 경우

아래에 해당하면 Hugging Face URL 제출보다 Docker 이미지 제출을 권장한다.

- 최신 평가 환경에서 아직 지원하지 않는 아주 최신 모델
 - 독자적인 모델 구조를 쓰는 모델
 - 추가 커스텀 코드 실행이 필요한 모델
 - private 또는 gated 모델처럼 Hugging Face 토큰이 필요한 모델
 - 로드 과정에 별도 패키지나 커스텀 환경 설정이 필요한 모델
- 이 경우에는 모델을 실제로 구동할 수 있는 Docker 이미지를 직접 제출하는 편이 훨씬 안전하다.

8. 자주 발생하는 실패 원인

8.1. 평가 환경에서 아직 로드되지 않는 모델

가장 흔한 실패 중 하나는 모델이 Hugging Face 에는 올라와 있지만, 현재 표준 vLLM 이미지가 그 구조를 아직 지원하지 않는 경우이다. 대표적인 예시는 아래와 같다.

- 공개된 지 며칠 안 된 너무 최신 모델
 - 독자적인 구조를 쓰지만 Hugging Face/Transformers 표준 아키텍처 등록이 아직 안 된 모델
 - vLLM 로그에 지원되지 않는 architecture 라는 메시지가 나오는 경우
- 이 경우 Hugging Face URL 제출은 실패할 수 있으며, 모델을 실제로 실행할 수 있는 Docker 이미지를 제출해야 한다.

8.2. Hugging Face repo 파일이 불완전한 경우

모델 가중치만 올라가 있고 설정 파일이 불완전하면 로드 단계에서 실패할 수 있다. 대표적인 예시는 아래와 같다.

- `config.json` 누락
- tokenizer 관련 파일 누락 또는 불일치
- tokenizer 설정이 잘못되어 초기화 단계에서 예외 발생
- 컨텍스트 길이 관련 메타데이터가 누락되어 장문 입력 처리 설정이 잘못 잡힘
즉, Hugging Face repo 는 "다운로드되는 된다" 수준이 아니라 "평가 환경에서 바로 로드된다" 수준으로 완결되어 있어야 한다.

8.3. 추가 커스텀 코드 실행이 필요한 모델

일부 모델은 Hugging Face repo 안의 별도 Python 코드를 실행해야만 로드된다. 이런 모델은 Hugging Face URL 제출에서 실패할 수 있다. 대표적인 예시는 아래와 같다.

- 커스텀 `modeling_*.py` 가 꼭 필요한 모델
 - 커스텀 tokenizer 구현이 필요한 모델
 - 별도 커스텀 코드 의존성이 큰 모델
- 이 경우에도 해당 모델을 실제로 실행할 수 있는 Docker 이미지를 제출하는 것이 맞다.

8.4. Hugging Face 토큰이 필요한 모델

private 모델이나 gated 모델처럼 Hugging Face 인증이 필요한 경우도 실패 원인이다. 이 제출 경로는 공개 repo 제출에 더 적합하다. 따라서 아래 경우는 Hugging Face URL 제출에 맞지 않는다.

- private repo
- gated access 승인 후 토큰이 있어야 내려받을 수 있는 모델
- 조직 내부 계정 인증이 필요한 모델

이 경우에는 해당 모델을 실제로 실행할 수 있는 Docker 이미지 제출을 사용하는 것이 맞다.

9. 로컬에서 제출 형태 그대로 검증하는 방법

실제 평가와 가장 비슷하게 확인하려면 로컬에서도 vLLM 기반 환경에서 직접 모델을 띄워봐야 한다. 예시는 아래와 같다.

```
docker run --rm --gpus all -p 8000:8000 \
  vllm/vllm-openai:latest \
  <HF_REPO_ID> \
  --host 0.0.0.0 \
  --port 8000 \
  --tensor-parallel-size 1 \
  --pipeline-parallel-size 1 \
  --dtype bfloat16 \
  --max-model-len 32768
```

그 다음 아래를 점검한다.

```
curl <http://localhost:8000/health>
curl <http://localhost:8000/v1/models>
```



예시 추론 요청:

```
curl <http://localhost:8000/v1/chat/completions> \
  -H "Content-Type: application/json" \
  -d '{
    "model": "<returned-model-id>",
    "messages": [
      {"role": "user", "content": "안녕하세요. 한 줄로 자기소개해
주세요."}
    ],
    "max_tokens": 64,
    "temperature": 0.0,
    "top_p": 1.0,
    "seed": 42
  }'
```

추가로 가능하면 긴 입력 테스트도 꼭 해보는 것이 좋다. 즉, 짧은 프롬프트만 통과하는지 보지 말고 실제 컨텍스트 길이에 가까운 입력에서도 로드와 추론이 안정적인지 확인한다.

10. 제출 전에 Hugging Face repo에서 꼭 확인할 것

제출 전에는 최소한 아래를 확인하는 것이 좋다.

- `config.json` 이 존재하는가
- tokenizer 관련 파일이 모두 존재하는가
- vLLM 기반 환경에서 실제 로드가 되는가
- `GET /health` , `GET /v1/models` , `POST /v1/chat/completions` 가 정상 동작하는가
- 긴 입력에서도 길이 제한 오류나 비정상 종료가 나지 않는가
- 외부 커스텀 코드 실행 없이 로드 가능한가
- 공개 접근 가능한 repo 인가

11. 자주 발생하는 제출 판단 기준

- 공개 repo 이고 별도 조치 없이 로드되는 모델이면 Hugging Face URL 제출 가능성이 높다.
- 로드 호환성이 애매하거나, 커스텀 코드나 토큰이 필요하거나, 최신 구조라 지원 여부가 불명확하면 Docker 이미지 제출이 더 적합하다.

특히 "내 로컬 환경에서는 된다" 가 곧 Hugging Face URL 제출 성공을 의미하지는 않는다. 로컬에서 성공했더라도 그것이 로컬 전용 설정, 로컬 토큰, 추가 패키지에 의존했다면 평가 환경에서는 실패할 수 있다.

12. 제출 전 체크리스트

- `modelUrl` 이 `https://huggingface.co/<org>/<repo>` 또는 `<org>/<repo>` 형태인가
- 해당 repo 가 공개적으로 접근 가능한가
- vLLM 기반 환경에서 별도 조치 없이 로드되는가
- `config.json` 과 tokenizer 파일이 완비되어 있는가



- GET /health 가 200 을 반환하는가
- GET /v1/models 가 유효한 id 를 반환하는가
- POST /v1/chat/completions 가 OpenAI 호환 응답을 반환하는가
- 긴 입력 요청에도 길이 제한 오류나 비정상 종료 없이 응답하는가
- 추가 커스텀 코드 의존 없이 로드 가능한가
- Hugging Face 토큰 없이도 다운로드 가능한가

13. 한 줄 요약

이 시스템의 Hugging Face URL 제출은 "제출된 repo 를 표준 vLLM 기반 평가 환경에서 그대로 로드 해 평가에 사용한다"는 계약이다. 따라서 제출 모델은 반드시 다음 조건을 만족해야 한다.

- 공개 Hugging Face repo 로 접근 가능
- vLLM 기반 평가 환경에서 바로 로드 가능
- config.json 및 tokenizer 파일 완비
- 추가 커스텀 코드 의존성이 크지 않음
- 긴 입력에도 안정적으로 응답