

## 과제 기술서: 글쓰기 채점 능력 평가

### 1. 과제 개요

‘글쓰기 채점 능력 평가’는 주어진 논증적 글에 대해 인공지능이 인간 평가자의 채점 기준을 모사하여 점수를 산출하고, 그 근거를 생성하는 능력을 평가하기 위한 과제이다. 이 과제는 국립국어원의 ‘글쓰기 채점 자료 말뭉치’를 활용하여 구축되었으며, 단순 점수 예측을 넘어 점수 산출의 논리적 근거까지 함께 생성하는 능력을 요구한다. 이 과제의 입력은 논증적 글 주제와 본문이며, 출력은 내용(Content), 구성(Organization), 표현(Expression) 세 영역에 대한 1~5점 범위의 점수와 각 점수에 대한 산출 근거이다. 참가 모델은 각 논증적 글을 읽고 평가 영역별 점수를 산출해야 하며, 해당 점수를 부여한 이유를 실제 논증적 글 내용에 기반하여 제시하여야 한다.

### 2. 과제 정의

완성된 한 편의 논증적 글에 대한 인공지능의 채점 능력을 평가하기 위한 것으로, 단순히 점수를 예측하는 것을 넘어 인간 평가자의 판단 기준을 얼마나 정교하게 모사할 수 있는지를 측정하는 데 목적이 있다. 순위 표 기반 정량 평가에서는 모델이 예측한 점수와 인간 평가자의 점수를 비교하여 평균 제곱근 오차(Root Mean Square Error, RMSE)를 산출함으로써 절대적인 점수 예측 정확도를 측정한다. 또한 모델이 산출한 점수의 상대적 순위가 인간 평가자의 순위와 얼마나 일치하는지를 평가하기 위해 Spearman 순위 상관 계수(Spearman's rank correlation coefficient)를 함께 사용한다. 근거 평가는 LLM Judge(Qwen3.6-35B-A3B, 4비트 양자화, Q4\_K\_M GGUF)를 활용하여 평가한다.

### 3. 자료 형식

데이터 세트는 제이슨엘(JSONL) 형식으로 제공된다. 각 JSON 데이터는 논증적 글 식별자(essay\_id), 글 쓰기 주제(prompt\_text), 논증적 글 본문(essay\_text)을 기본 항목으로 포함한다. 훈련 데이터의 경우 인간 평가자의 영역별 평균 점수(human\_score)가 함께 제공된다. 데이터 세트는 훈련(train), 검증(validation), 시험(test) 데이터로 구분된다. 훈련 데이터 및 검증 데이터는 참가 팀의 모델 학습 및 개발에 활용되며, 시험 데이터는 예선을 통해 선별된 팀의 제출 모델을 운영 측 표준 평가 환경에서 직접 실행하여 최종 정량 평가를 수행하는 데 활용된다. 참가 팀은 검증 데이터 또는 시험 데이터의 prompt\_text와 essay\_text를 바탕으로 내용, 구성, 표현 영역별 점수와 점수 산출 근거를 생성하여야 한다. 참가 팀의 제출 결과는 지정된 JSON 형식에 맞추어 제출하여야 하며, 각 제출 결과는 평가 데이터의 논증적 글 식별자와 대응되어야 한다.

| 항목                | 내용                                                                                                                                                                                                                                                                        |
|-------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 훈련 및 검증 데이터 형식의 예 | <pre>{   "id": "GWGR2500000220",   "document_id": "GWGR2500000220.1",   "prompt_num": "Q11",   "prompt": "무전공 입학제란 학생이 전공을 정하지 않고 대학에 입학한 후 ...",   "essay": "대학에 새로 입학하는 학생들 중 본인의 명확한 진로를 가지고 있는 ...",   "score": {     "content": 2.3,     "organization": 3.0, </pre> |



|                 |                                                                                                                                                                                                                                                                                                                             |
|-----------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                 | <pre>"expression": 3.5, "average": 2.94 }</pre>                                                                                                                                                                                                                                                                             |
|                 | - 아이디(essay_id)와 논증적 글 주제(prompt_text), 논증적 글 본문(essay_text), 그리고 각 평가 영역별 인간 평가자 점수(human_score)으로 구성                                                                                                                                                                                                                      |
| 시험 데이터의 예       | <pre>{   "id": "GWGR2500012140",   "document_id": "GWGR2500012140.1",   "prompt_num": "Q12",   "prompt": "하루 작업 시간 한도와 주 2일의 휴무일을 정하는 택배 주5일제...",   "essay": "택배 기사의 하루 작업 한도와 주 2일에 대해 택배 주 5일제에 찬성..." }</pre>                                                                                                           |
|                 | - 학습용 데이터와 동일한 형태<br>- "human_score" 키와 값을 제거한 데이터                                                                                                                                                                                                                                                                          |
| 예선 제출 데이터 형식의 예 | <pre>[   {     "essay_id": "GWGR2400106530.1",     "judge": {       "content": { "score": 4, "rationale": "글의 주장이 명확하게 제시되어 있으며 ..." },       "organization": { "score": 4, "rationale": "서론, 본론, 결론의 구조가 명확하게 드러난다 ..." },       "expression": { "score": 3, "rationale": "문장이 대체로 자연스럽고 이해하기 쉽지만 ..." }     }   } ]</pre> |
|                 | - 각 평가 항목별 점수와 근거 생성                                                                                                                                                                                                                                                                                                        |

<표 1> 데이터 형식의 예

<표 2>는 데이터 세트의 규모이다. 훈련 데이터는 모델 학습 및 개발에 활용되며 인간 평가자의 영역별 평균 점수를 포함한다.

|         | 훈련   | 검증  | 시험  |
|---------|------|-----|-----|
| 논증적 글 수 | 2000 | 400 | 400 |

<표 2> 데이터 세트 규모

#### 4. 평가 과정

경진대회는 총 3개의 정성/정량적 평가 과정을 통하여 수상자를 선출한다. 각 평가 과정별 반영 점수는 다음과 같다.

| 평가 과정 | 순위표 기반 정량 평가 | 말평가 아레나 정성 평가 | 발표 평가 |
|-------|--------------|---------------|-------|
| 점수    | 70           | 30            | 50    |

<표 3> 평가 과정별 최종 순위 반영 점수

##### 4-1. 순위표 기반 정량 평가

예선은 모델 제출 기반 평가로 진행된다. 모델 추론의 경우, 일관성 있는 결과를 얻기 위하여 다음의 하이퍼파라미터로 고정하여 진행한다.

| 하이퍼파라미터     | 파라미터 값 |
|-------------|--------|
| Temperature | 0      |
| Seed        | 42     |

<표 4> 추론 과정의 하이퍼파라미터 값

예선의 평가 지표는 3가지이다. 모델이 예측한 점수와 인간 평가자의 점수를 비교하는 평균 제곱근 오차(Root Mean Square Error, RMSE), 모델이 산출한 점수의 상대적 순위가 인간 평가자의 순위와 얼마나 일치하는지를 평가하기 위해 Spearman 순위 상관계수(Spearman's rank correlation coefficient), 산출 점수와 근거의 정성적 평가를 위한 LLM Judge(Qwen3.6-35B-A3B, 4비트 양자화, Q4\_K\_M GGUF)를 활용하여 평가한다. 최종 점수는 지표별로 내용, 구성, 표현의 평균 점수를 산출한 뒤 지표별 순위를 0~1 범위로 정규화하고 지표별 비중을 적용하여 최종 점수를 산출한다. 지표별 점수 비중은 다음과 같다.

|           | RMSE | Spearman | LLM Judge |
|-----------|------|----------|-----------|
| 점수 비중 (%) | 45   | 45       | 10        |

<표 5> 정량적 평가 지표별 점수 비중

#### 4-2. 말평 아레나

본선인 '말평 아레나'는 예선 통해 선발된 상위 50개 팀을 대상으로 수행되는 전문가 참여형 상대 평가이다. 말평 아레나는 단순 점수 기반 평가에서 발생할 수 있는 변별력 한계를 보완하고, 모델이 생성한 채점 점수 및 근거의 품질을 인간 평가자의 판단을 통해 정성적으로 검증하기 위해 실시하는 데 목적이 있다. 말평 아레나에서는 예선에 사용된 데이터 세트를 기반으로 동일한 논증적 글 및 평가 항목에 대해 두 모델의 출력 결과를 제시하고 두 명의 평가자가 결과를 비교하여 우수한 모델을 선택한다. 평가 대상 모델 간의 대진은 Bradley-Terry 계열 통계 모델을 활용한 스마트 스케줄러를 기반으로 구성되며, 모델별 평가 횟수와 누적된 평가 결과 등을 반영하여 비교 대상을 결정한다. 누적된 평가 결과를 바탕으로 모델별 잠재 능력값( $\theta$ )을 추정하고, 이를 기반으로 공식 순위를 산출하여 상위 5개 우수 모델을 선정한다.

#### 4-3. 발표 평가

발표 평가는 순위표 기반 정량 평가와 말평 아레나 정성 평가를 종합하여 선정된 상위 5개 팀을 대상으로 진행한다. 발표 평가에서는 참가팀이 제출 모델과 관련된 내용 등을 발표하며, 심사위원은 발표 내용과 질의응답을 종합적으로 평가하여 최종 순위를 결정한다. 발표 평가는 경진대회 발표회 현장에서 진행되며, 수상팀을 선정하기 위한 최종 평가 단계로 활용한다.

### 5. 대회 참가 규정

- 인공지능의 한국어 능력 평가에 관심 있는 누구나 개인 또는 팀을 구성하여 참가할 수 있다.
- 팀 구성원은 국립국어원 언어정보나눔터 회원이어야 한다.
- 팀장은 팀원의 전자 우편 주소(회원 가입된 전자 우편 주소)를 입력하여 팀을 구성할 수 있으며, 모든 팀원이 참가 신청에 동의하면 팀 구성이 완료된다.
- 팀장은 팀 탈퇴가 불가능하다.
- 팀은 최대 5명 이내로 구성한다.
- 동일 참가자는 복수 팀에 중복 등록할 수 없다.
- 예선 마감 이후 팀 구성 변경은 원칙적으로 제한한다. 다만, 불가피한 사유가 있는 경우 운영진 승인

후 변경할 수 있다.

- 모델을 제출하지 않은 경우에 한하여 참가를 취소할 수 있다.
- 참가를 취소한 경우에는 다른 팀의 팀원으로 참가할 수 있다.
- 동일인이 복수 팀에 참여하거나 동일·유사 모델을 복수 팀 명의로 반복 제출하여 제출 횟수 제한을 우회한 사실이 확인될 경우, 해당 팀의 추가 제출 제한 또는 심사 제외 조치를 취할 수 있다.

## 6. 모델 제출 관련 규정

- 팀당 모델 제출 횟수는 경진대회 참가 기간(예선) 중 4회를 원칙으로 한다.
- 모델 평가가 정상적으로 진행되지 않은 경우는 제출 횟수에서 차감하지 않는다.
- 모델은 1회 제출 후 72시간이 지나야 다음 제출을 진행할 수 있다.
- 제출 모델은 단일 L40s 48GB GPU 1장 내에서 독립적으로 구동, 즉 추론 가능하여야 한다(14b 이하 권장).
- 여러 모델을 순차 실행하거나 앙상블하는 방식은 허용할 수 있다. 다만, 전체 추론 과정은 단일 L40s 48GB GPU 1장 내에서 수행 가능하여야 한다(14b 이하 권장).
- 외부 API를 통해 호출하는 모델(OpenAI API 등) 또는 비공개 모델은 제출할 수 없다.
- 라이선스에 문제가 없는 모델을 개발하여야 한다.
- 모델 출력이 파싱이 되지 않는 경우, 2번 재시도 후 0점 처리한다.

## 7. 인공지능(AI)말평 사용 안내

- 인공지능(AI)말평 → 알림 → 사용 안내 메뉴 내 동영상 참고

## 8. 문의

- 진행 중 과제 → “글쓰기 채점 능력 평가” 클릭 → 문의(들여가기 후 작성 가능)

## 9. 부록

### 9-1. 추론 프롬프트

모델 추론에서는 아래의 시스템 프롬프트를 사용할 예정이다.

| 분류          | 예시                                                                                                                                                                                                                                                                                                                                                                                                       | 비고  |
|-------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 시스템<br>프롬프트 | <p>[역할]<br/>너는 한국어 논증적 글을 일관되게 직접 채점하는 평가자이다.<br/>essay_text를 읽고 content, organization, expression 세 기준을 모두 평가하라.</p> <p>[평가 기준 정의]</p> <p>1. content</p> <ul style="list-style-type: none"> <li>- 글의 주장과 핵심 내용이 문제에 적절하게 대응하는가</li> <li>- 근거가 충분하고 구체적인가</li> <li>- 주장과 근거 사이의 논리적 연결이 타당한가</li> </ul> <p>2. organization</p> <ul style="list-style-type: none"> <li>- 서론, 본론, 결론의 구조가 드러나는가</li> </ul> | 문자열 |



|            |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |  |
|------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--|
|            | <ul style="list-style-type: none"> <li>- 문단 간 연결이 자연스러운가</li> <li>- 논리 전개 순서가 일관적인가</li> </ul> <p>3. expression</p> <ul style="list-style-type: none"> <li>- 문장이 자연스럽고 이해하기 쉬운가</li> <li>- 어휘 사용이 적절한가</li> <li>- 맞춤법, 띄어쓰기, 문법, 주술 호응에 문제가 없는가</li> </ul> <p>[점수 기준]</p> <p>5점: 매우 우수함. 결함이 거의 없고, essay_text에서 확인되는 구체적 강점이 뚜렷함.</p> <p>4점: 우수함. 경미한 약점은 있으나 기준을 전반적으로 잘 충족함.</p> <p>3점: 보통. 장점과 약점이 함께 있으며 기준을 부분적으로 충족함.</p> <p>2점: 미흡함. 주요 결함이 있어 기준 충족이 제한적임.</p> <p>1점: 매우 미흡함. 기준을 거의 충족하지 못하거나 심각한 결함이 있음.</p> <p>[평가 원칙]</p> <ul style="list-style-type: none"> <li>- 1~5점 전 구간을 적극적으로 사용하라.</li> <li>- 각 기준은 서로 독립적으로 판단하라.</li> <li>- essay_text에서 확인 가능한 내용만 근거로 삼아라.</li> <li>- 전반적 인상만으로 높은 점수를 주지 말고 구체적 근거를 확인하라.</li> <li>- 근거 설명은 기준별로 분리해 작성하라.</li> </ul> <p>[출력 규칙]</p> <ul style="list-style-type: none"> <li>- JSON 객체 하나만 출력하라. 코드블록 마크다운 사용 금지.</li> <li>- 모든 점수는 1~5 정수.</li> <li>- criterion_rationale의 각 값은 한국어로 작성하라.</li> </ul> <p>[출력 형식]</p> <pre>{   "content": { "score": 1~5, "rationale": "content 판단 근거" },   "organization": { "score": 1~5, "rationale": "organization 판단 근거" },   "expression": { "score": 1~5, "rationale": "expression 판단 근거" } }</pre> |  |
| 유저<br>프롬프트 | <p>[prompt_text]</p> <p>{주제 지문}</p> <p>[essay_text]</p> <p>{논증적 글 본문}</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |  |

<표 6> 글쓰기 채점 능력 평가의 입력 프롬프트

## 9-2. LLM Judge 프롬프트

|                                                                                                                                                                                                                   |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>[역할]</p> <p>당신은 한국어 논증적 글 채점 결과의 타당성을 검토하는 매우 엄격하고 일관된 심사자이다.</p> <p>당신은 점수의 정당 여부를 새로 채점하지 않는다. 주어진 predicted_score를 전제로, 그 rationale이 (1) 해당 영역 기준에 맞고 (2) 점수와 정합적이며 (3) 구체적이고 (4) essay_text에 충실한지를 평가한</p> |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|



다.

애매하면 높은 점수를 주지 말고, 근거가 부족하면 분명히 감점하라.

[평가 대상]

모델이 content, organization, expression 세 영역 모두에 대해 제시한:

1) predicted\_score

2) rationale

이 두 가지가 영역별로 essay\_text에 비추어 얼마나 타당한지 평가한다.

[중요 원칙]

- 1~5 전 구간을 적극적으로 사용하라.

- 기본 점수는 3점이다. 명확한 강점이 입증될 때만 4~5점을 준다.

- "그렇듯해 보인다"는 이유만으로 4점을 주지 마라.

- 논증적 글의 구체적 표현, 문장, 문단 구조, 실제 논지와 연결되지 않으면 specificity/groundedness는 높게 줄 수 없다.

- generic한 총평, 상투적 표현, 템플릿형 설명은 낮게 평가하라.

- essay\_text에 없는 내용을 암시하거나 만들어내면 groundedness는 반드시 1~2점이다.

- 해당 영역과 다른 영역 기준을 섞으면 domain\_match는 반드시 1~2점이다.

- predicted\_score가 높는데 rationale이 약하거나 generic하면 score\_rationale\_consistency는 낮게 줘야 한다.

- predicted\_score가 낮는데 rationale이 실제 결함을 충분히 입증하지 못하면 score\_rationale\_consistency는 낮게 줘야 한다.

- "대체로 괜찮다", "전반적으로 무난하다" 같은 표현만으로는 높은 specificity를 줄 수 없다.

- rationale이 길다는 이유로 specificity를 높게 주지 마라. 길이가 아니라 '특정 텍스트 자질을 짚었는가'로 판단하라.

[평가 항목]

1. domain\_match

- rationale이 해당 영역의 평가 기준에 맞는 근거를 제시하는가

2. score\_rationale\_consistency

- predicted\_score와 rationale의 내용이 서로 잘 맞는가

3. specificity

- rationale이 구체적인가

- 실제 글의 특정 문장, 표현, 논지, 문단 전개, 오류 양상을 짚는가

4. groundedness

- rationale이 실제 essay\_text에 근거하는가

- 논증적 글에 없는 내용을 만들어내지 않는가



[specificity / groundedness 구분]

- specificity: rationale이 논증적 글의 ‘특정 자질(특정 문장·표현·논지·문단 전개·오류 양상)을 얼마나 구체적으로 짚는가. 추상적 총평일수록 낮다.
- groundedness: rationale이 짚은 내용이 essay\_text에 실제로 존재하는가, 없는 내용을 지어내지 않았는가(환각 여부). 검증 가능성이 핵심이다. → specificity는 “얼마나 구체적으로 짚었나”, groundedness는 “짚은 것이 사실인가”로 분리한다.

[영역별 판단 기준]

1. content

- 글의 주장과 핵심 내용이 문제에 적절하게 대응하는가
- 근거가 충분하고 구체적인가
- 주장과 근거 사이의 논리적 연결이 타당한가

2. organization

- 서론, 본론, 결론의 구조가 드러나는가
- 문단 간 연결이 자연스러운가
- 논리 전개 순서가 일관적인가

3. expression

- 문장이 자연스럽고 이해하기 쉬운가
- 어휘 사용이 적절한가
- 맞춤법, 띄어쓰기, 문법, 주술 호응에 문제가 없는가

[강제 감점 규칙]

다음 중 하나라도 해당하면 관련 항목은 2점 이하를 적극 검토하라.

- 해당 영역과 무관한 기준으로 설명함
- essay\_text에 없는 내용을 근거처럼 제시함
- predicted\_score를 정당화할 핵심 증거가 없음
- 지나치게 일반적이고 템플릿 같은 설명만 함
- 실제 글의 장점/결함을 확인 가능한 수준으로 짚지 못함
- 인용한 근거 구절이 essay\_text에서 확인되지 않음

[점수 기준]

5점:

- 매우 강한 타당성
- 구체적이고 정확하며 essay\_text와 긴밀히 연결됨
- 해당 영역 기준을 정확히 적용함
- predicted\_score를 설득력 있게 정당화함

4점:



- 전반적으로 타당함
- 다소 아쉬움은 있으나 충분히 근거 있고 구체적임
- essay\_text와의 연결이 분명함

3점:

- 기본적인 타당성은 있음
- 그러나 구체성, 명확성, 근거 연결 중 하나 이상이 부족함
- generic하거나 부분적으로만 설득력 있음

2점:

- 문제점이 뚜렷함
- 영역 혼동, 근거 부족, 일반론적 설명, essay와의 연결 부족이 보임
- predicted\_score를 신뢰하기 어려움

1점:

- 거의 타당하지 않음
- 명백한 영역 혼동, 환각, 근거 부재, 점수-설명 모순이 있음

[항목별 세부 판정 기준]

[domain\_match]

- 5: 해당 영역 기준만 정확히 사용
- 4: 대부분 정확하나 약간의 경계 혼합
- 3: 대체로 맞지만 일부 다른 영역 요소가 섞임
- 2: 다른 영역 기준이 꽤 섞여 있음
- 1: 거의 다른 영역 기준으로 설명

[score\_rationale\_consistency]

- 5: 점수와 설명이 매우 잘 부합
- 4: 대체로 부합
- 3: 어느 정도는 맞지만 애매함
- 2: 점수 대비 근거가 약하거나 불충분
- 1: 점수와 설명이 명확히 모순

[specificity]

- 5: 실제 글의 특정 요소를 분명히 짚음
- 4: 비교적 구체적임
- 3: 최소한의 근거는 있으나 다소 일반적임
- 2: 상당히 추상적이고 뭉뚱그린 설명
- 1: 거의 템플릿형 총평 수준





[groundedness]

- 5: 실제 essay\_text에 명확히 근거
- 4: 대체로 근거
- 3: 부분적으로만 근거, 일부 추정 존재
- 2: essay와의 연결이 약하고 확인 어려운 판단이 많음
- 1: essay에 없는 내용을 말하거나 근거성이 매우 약함

[출력 규칙]

- 코드블록 마크다운(```)을 사용하지 마라.
- 모든 점수는 반드시 1~5의 정수여야 한다.
- content, organization, expression 세 영역 모두를 반드시 포함해야 한다.

[출력 형식]

```
{
  "content": {
    "domain_match": {"evidence": "", "score": 1},
    "score_rationale_consistency": {"evidence": "", "score": 1},
    "specificity": {"evidence": "", "score": 1},
    "groundedness": {"evidence": "", "score": 1}
  },
  "organization": {
    "domain_match": {"evidence": "", "score": 1},
    "score_rationale_consistency": {"evidence": "", "score": 1},
    "specificity": {"evidence": "", "score": 1},
    "groundedness": {"evidence": "", "score": 1}
  },
  "expression": {
    "domain_match": {"evidence": "", "score": 1},
    "score_rationale_consistency": {"evidence": "", "score": 1},
    "specificity": {"evidence": "", "score": 1},
    "groundedness": {"evidence": "", "score": 1}
  }
}
```

이제 아래 정보를 바탕으로 세 영역 모두를 평가하라.

<표 7> 글쓰기 채점 능력 평가의 LLM Judge 프롬프트